

Trabajo Práctico 3: Teoría de la información

Compactadores - Fuentes de Markov

Profesores:

Mag. Ing. Raúl Oscar Klenzi

Lic. Manuel Oscar Ortega

Lic. Fabrizio Amaya

Alumnos:

Figueroa Santiago E010-186

Ríos Matias E010-133

Zalazar Lucas E010-340

Grupo 9

Parte 1, Compactadores:

a) Clasificación:

Código A:

- Es bloque, pues todos tienen longitud 3
- Es no singular, todas las palabras son diferentes.
- Es instantáneo como todas tienen la misma longitud, ninguna puede ser prefijo de otra.
- Al ser instantáneo, automáticamente es unívocamente decodificable.

Código B:

- No es bloque, pues todos tienen una longitud diferente. (1,2,3,4,5, 6)
- Es no singular, todas las palabras son diferentes.
- No es instantáneo, pues 0 es prefijo de 01, 011, etc.
- Es decodificable ya que cada palabra empieza con un 0 y continúa con una cantidad determinada de , en donde cada 0 marca un nuevo comienzo de la palabra.

Código C:

- No es bloque, todos tienen longitudes diferentes.
- Es no singular, todas las palabras son diferentes.
- Es instantáneo.
- Es unívocamente decodificable.

Código D:

- No es bloque.
- Es no singular
- No es instantáneo, ya que por ejemplo 10 es prefijo de 1011.
- No es decodificable, porque podemos demostrarlo encontrando dos formas diferentes de obtener la misma secuencia.

$s_2s_3=10+110=10110$ o también $s_5s_1=1011+0=10110$

Código E:

- No es bloque.
- Es no singular
- Es instantáneo, ningún código es prefijo de otro.
- Es unívocamente decodificable, ya que es instantáneo.

Código F:

- No es bloque
- Es no singular.
- No es instantáneo, pues 0 es prefijo de 001
- No es UD, ya que podemos encontrar que $s_1s_1s_2=00100$ y $s_6s_1s_1=00100$

B) Longitud promedio de los códigos UD: **A,B,C,E**

La fórmula es:

$$L = \sum_i p_i n_i$$

p_i = probabilidad del símbolo

n_i = longitud de su palabra código.

Código A

Todas las palabras tienen longitud 3:

$$L_A = \frac{1}{2}(3) + \frac{1}{4}(3) + 4\left(\frac{1}{16}\right)(3)$$

$$L_A = 1.5 + 0.75 + 0.75$$

$$\boxed{L_A = 3}$$

Código B

Las longitudes son:

1, 2, 3, 4, 5, 6

Entonces:

$$L_B = \frac{1}{2}(1) + \frac{1}{4}(2) + \frac{1}{16}(3) + \frac{1}{16}(4) + \frac{1}{16}(5) + \frac{1}{16}(6)$$

$$L_B = 0.5 + 0.5 + 0.1875 + 0.25 + 0.3125 + 0.375$$

$$L_B = 2.125$$

Código C

Tiene exactamente las mismas longitudes que B:

1, 2, 3, 4, 5, 6

Por lo tanto:

$$L_C = 2.125$$

Código E

Las longitudes son:

1, 2, 4, 4, 4, 4

Entonces:

$$L_E = \frac{1}{2}(1) + \frac{1}{4}(2) + 4 \left(\frac{1}{16} \right) (4)$$

$$L_E = 0.5 + 0.5 + 1$$

$$L_E = 2$$

c)

Código B:

Una forma sencilla de transformarlo en instantáneo manteniendo las mismas longitudes es reemplazarlo por:

0, 10, 110, 1110, 11110, 111110

(Es el mismo que C)

Código D:

No es instantáneo y además no es UD.

Una modificación posible es aumentar a 5 bits las dos últimas palabras y dejarlas:

0, 10, 110, 1110, 11110, 11111

Ahora sí resulta instantáneo y, por lo tanto, UD.

Código F:

No es UD, por lo tanto

Una modificación posible es aumentar dos palabras de longitud 3 a longitud 4. Por ejemplo:

0, 100, 101, 110, 1110, 1111

no tiene ninguna palabra como prefijo de otra, por lo que es **instantáneo y UD**.

Ejercicio 2

Para determinar si un conjunto de longitudes puede corresponder a un código unívocamente decodificable, usamos la desigualdad de Kraft-McMillan:

$$\sum_i 3^{-l_i} \leq 1$$

Código A:

2 palabras de longitud 1

1 palabra de longitud 2

2 palabras de longitud 3

1 palabra de longitud 4

4 palabras de longitud 5

Aplicamos Kraft:

$$K_A = 2 \left(\frac{1}{3} \right) + 1 \left(\frac{1}{9} \right) + 2 \left(\frac{1}{27} \right) + 1 \left(\frac{1}{81} \right) + 4 \left(\frac{1}{243} \right)$$

Llevamos todo a denominador 243:

$$K_A = \frac{162 + 27 + 18 + 3 + 4}{243}$$
$$K_A = \frac{214}{243}$$

Como:

$$\frac{214}{243} < 1$$

el conjunto es **válido**.

Código A: VÁLIDO

Código B

$$K_B = 2 \left(\frac{1}{3} \right) + 2 \left(\frac{1}{9} \right) + 2 \left(\frac{1}{27} \right) + 3 \left(\frac{1}{81} \right) + 1 \left(\frac{1}{243} \right)$$

$$K_B = \frac{162 + 54 + 18 + 9 + 1}{243}$$

$$K_B = \frac{244}{243}$$

Como:

$$\frac{244}{243} > 1$$

no puede existir un código instantáneo ni unívocamente decodificable con esas longitudes.

Código B: NO VÁLIDO

Código C

$$K_C = 1 \left(\frac{1}{3} \right) + 4 \left(\frac{1}{9} \right) + 6 \left(\frac{1}{27} \right)$$

$$K_C = \frac{1}{3} + \frac{4}{9} + \frac{6}{27}$$

Como:

$$\frac{6}{27} = \frac{2}{9}$$

tenemos:

$$K_C = \frac{1}{3} + \frac{4}{9} + \frac{2}{9}$$

$$K_C = \frac{3}{9} + \frac{4}{9} + \frac{2}{9}$$

$$K_C = \frac{9}{9} = 1$$

Código C Válido.

Código D

$$K_D = 2 \left(\frac{1}{3} \right) + 2 \left(\frac{1}{9} \right) + 2 \left(\frac{1}{27} \right) + 2 \left(\frac{1}{81} \right) + 3 \left(\frac{1}{243} \right)$$

$$K_D = \frac{162 + 54 + 18 + 6 + 3}{243}$$

$$K_D = \frac{243}{243} = 1$$

Por lo tanto:

Código D: VÁLIDO

b) **Código A:**

Símbolo	Código	Longitud
s_1	0	1
s_2	1	1
s_3	20	2
s_4	210	3
s_5	211	3
s_6	2200	4
s_7	22010	5
s_8	22011	5
s_9	22012	5
s_{10}	22020	5

Código C:

Símbolo	Código	Longitud
s_1	0	1
s_2	10	2
s_3	11	2
s_4	12	2
s_5	20	2
s_6	210	3
s_7	211	3
s_8	212	3
s_9	220	3
s_{10}	221	3

s_{11}	222	3
----------	------------	----------

Código D:

Símbolo	Código	Longitud
s_1	0	1
s_2	1	1
s_3	20	2
s_4	21	2
s_5	220	3
s_6	221	3
s_7	2220	4
s_8	2221	4

s_9	22220	5
s_{10}	22221	5
s_{11}	22222	5

3.

Un código coma utiliza un símbolo especial, llamado coma, que aparece al final de cada palabra y no aparece en ninguna otra posición de la palabra. Por ejemplo, en un código binario:

0, 10, 110, 1110, ...

el símbolo 0 funciona como coma. Los códigos coma son códigos prefijo.

Vamos a demostrar que cumplen la desigualdad de Kraft.

Supongamos que tenemos un código coma sobre un alfabeto de r símbolos.

Si una palabra tiene longitud l :

- La última posición está obligatoriamente ocupada por la coma.
-
- Las primeras $l - 1$ posiciones pueden utilizar cualquiera de los otros $r - 1$ símbolos.
-

Por lo tanto, la cantidad máxima de palabras de longitud l es:

$$(r - 1)^{l-1}$$

Entonces, si n_l es la cantidad de palabras de longitud l :

$$n_l \leq (r - 1)^{l-1}$$

La desigualdad de Kraft es:

$$\sum n_l \cdot r^{-l} \leq 1$$

Como:

$$n_l \leq (r - 1)^{l-1}$$

tenemos:

$$\sum n_l \cdot r^{-l} \leq \sum (r - 1)^{l-1} \cdot r^{-l}$$

Sacamos $1/r$:

$$= (1/r) \cdot \sum [(r-1) / r]^l$$

Esta es una serie geométrica:

$$\sum (q)^{l-1} = 1 / (1 - q) \text{ (desde } l = 1 \text{ hasta } \infty)$$

con:

$$q = (r-1) / r$$

Entonces:

$$(1/r) \cdot [1 / (1 - (r-1) / r)] = (1/r) \cdot [1 / (1/r)] = 1$$

Por lo tanto:

$$\sum n_l \cdot r^l \leq 1$$

Así demostramos que:

Todo código coma cumple la desigualdad de Kraft.

4.

Sea código ternario $r=3$

Aplicamos kraft:

$$K = 3^{-1} + 5(3^{-2}) + 4(3^{-3})$$

$$K = \frac{1}{3} + \frac{5}{9} + \frac{4}{27}$$

Llevamos todo a denominador 27:

$$K = \frac{9}{27} + \frac{15}{27} + \frac{4}{27}$$

$$K = \frac{28}{27}$$

Como:

$$\boxed{\frac{28}{27} > 1}$$

no es posible codificar los 10 dígitos con esas longitudes.

Tenemos:

$$1/3 + 5 \cdot (1/9) = 1/3 + 5/9 = 3/9 + 5/9 = 8/9$$

Nos queda disponible:

$$1 - 8/9 = 1/9$$

Como $1/27$ corresponde a una palabra de longitud 3, podemos colocar como máximo:

$$(1/9) / (1/27) = 3 \text{ palabras de longitud 3.}$$

Por lo tanto, podemos tener:

- 1 palabra de longitud 1
- 5 palabras de longitud 2
- 3 palabras de longitud 3


Total:

$$1 + 5 + 3 = 9$$

Por lo tanto:

Como máximo podemos codificar 9 dígitos.

Árbol de codificación:



5.

La fórmula de la entropía es:

$$H(X) = - \sum_i p_i \log_2(p_i)$$

Entonces:

$$H(X) = -[0,30 \log_2(0,30) + 0,25 \log_2(0,25) + 0,18 \log_2(0,18) \\ + 0,12 \log_2(0,12) + 0,08 \log_2(0,08) + 0,07 \log_2(0,07)]$$

Símbolo	p_i	$-p_i \log_2 p_i$ 
A	0,30	0,5211
B	0,25	0,5000
C	0,18	0,4450
D	0,12	0,3671
E	0,08	0,2915
F	0,07	0,2681

Por lo tanto:

$$H(X) \approx 2,3935 \text{ bits/símbolo}$$

Para Shannon:

$$l_i = \lceil -\log_2(p_i) \rceil$$

Calculamos las longitudes:

Símbolo	Prob.	$-\log_2(p_i)$	Longitud 
A	0,30	1,737	2
B	0,25	2	2
C	0,18	2,474	3
D	0,12	3,059	4
E	0,08	3,644	4
F	0,07	3,837	4

Para Fano: Ordenamos de mayor a menor probabilidad:

$$A(0,30), B(0,25), C(0,18), D(0,12), E(0,08), F(0,07)$$

Dividimos el conjunto intentando que las probabilidades de los dos grupos sean lo más cercanas posible:

Primera división

$$A + B = 0,55$$

$$C + D + E + F = 0,45$$

Asignamos:

- Primer grupo → 0
- Segundo grupo → 1

Grupo AB: dividimos.

$$A=0,30$$

$$B=0,25$$

Grupo CDEF:

$$C+D=0,30$$

$$E+F=0,15$$

Un código de Fano posible es:

Símbolo	Código	Longitud
A	00	2
B	01	2
C	100	3
D	101	3

E	110	3
F	111	3

Para Huffman:

Ordenamos : |0,30 | 0,25 | 0,18 | 0,12 | 0,08 | 0,07|

Paso 1

$$0,07 + 0,08 = 0,15$$

Tenemos: 0,12, 0,15, 0,18, 0,25, 0,30

Paso 2

$$0,12 + 0,15 = 0,27$$

Tenemos: 0,18, 0,25, 0,27, 0,30

Paso 3

$$0,18 + 0,25 = 0,43$$

Tenemos: 0,27, 0,30, 0,43

Paso 4


$$0,27 + 0,30 = 0,57$$

Tenemos: 0,43, 0,57

Paso 5

$$0,43 + 0,57 = 1$$

Árbol:



Símbolo	Código	Longitud
A	10	2
B	01	2
C	00	2
D	110	3
E	1110	4
F	1111	4

c) Longitud promedio, eficiencia y redundancia.

Fórmulas:

Longitud promedio

$$L = \sum_i p_i l_i$$

Eficiencia

$$\eta = \frac{H(X)}{L}$$

Redundancia

$$R = 1 - \eta$$

Código de Shannon

Las longitudes son:

2, 2, 3, 4, 4, 4

Entonces:

$$L_{\square} = 0,30(2) + 0,25(2) + 0,18(3) + 0,12(4) + 0,08(4) + 0,07(4)$$

$$L_{\square} = 0,60 + 0,50 + 0,54 + 0,48 + 0,32 + 0,28$$

$$L_{\square} = 2,72$$

Eficiencia

$$\eta_{\square} = 2,3935 / 2,72$$

$$\eta_{\square} \approx 0,87997$$

En porcentaje:

$$\eta_{\square} \approx 88,00\%$$

Redundancia

$$R_{\square} = 1 - 0,87997$$

$$R_{\square} \approx 0,12003$$

$$R_{\square} \approx 12,00\%$$

Código de Fano

Las longitudes son:

2, 2, 3, 3, 3, 3

Entonces:

$$L_{\square} = 0,30(2) + 0,25(2) + 0,18(3) + 0,12(3) + 0,08(3) + 0,07(3)$$

$$L_{\square} = 0,60 + 0,50 + 0,54 + 0,36 + 0,24 + 0,21$$

$$L_{\square} = 2,45$$

Eficiencia

$$\eta_{\square} = 2,3935 / 2,45$$

$$\eta \approx 0,97695$$

$$\eta \approx 97,70\%$$

Redundancia

$$R = 1 - 0,97695$$

$$R \approx 0,02305$$

$$R \approx 2,30\%$$

Código de Huffman

Las longitudes son:

2, 2, 2, 3, 4, 4

Entonces:

$$L = 0,30(2) + 0,25(2) + 0,18(2) + 0,12(3) + 0,08(4) + 0,07(4)$$

$$L = 0,60 + 0,50 + 0,36 + 0,36 + 0,32 + 0,28$$

$$L = 2,42$$

Eficiencia

$$\eta = 2,3935 / 2,42$$

$$\eta \approx 0,98906$$

$$\eta \approx 98,91\%$$

Redundancia

$$R = 1 - 0,98906$$

$$R \approx 0,01094$$

$$R \approx 1,09\%$$

d) Comparación

Método	Longitud promedio L	Eficiencia η	Redundancia R
Shannon	2,72	87,997 %	12,003 %
Fano	2,45	97,695 %	2,305 %
Huffman	2,42	98,906 %	1,094 %
Entropía	2,3935	—	—

La entropía es:

$$H(X) = 2,3935$$

y las longitudes promedio obtenidas son:

$$L_{\square} = 2,72$$

$$L_{\square} = 2,45$$

$$L_{\square} = 2,42$$

Por el teorema de codificación de fuente:

$$H(X) \leq L$$

Por eso ningún código binario instantáneo puede tener una longitud promedio inferior a la entropía.

En este caso, Huffman obtiene:

$$L_{\square} = 2,42$$

que está muy cerca de:

$$H(X) = 2,3935$$

La diferencia es:

$$2,42 - 2,3935 = 0,0265$$

Por lo tanto, Huffman es el que más se aproxima al límite teórico de la entropía para esta fuente.

6. Cadena: ERRECONERRECIGARROERRECONERREBARRIL

d = distancia hacia atrás donde comienza la coincidencia.

l = longitud de la coincidencia.

c = siguiente carácter después de la coincidencia.

(0,0,c) si no hay coincidencias.

#	Tupla	Cadena que reconstruye
1	(0,0,E)	E
2	(0,0,R)	R
3	(1,1,E)	RE
4	(0,0,C)	C
5	(0,0,O)	O
6	(0,0,N)	N
7	(4,1,R)	ER
8	(1,1,E)	RE
9	(0,0,C)	C
10	(0,0,I)	I
11	(0,0,G)	G
12	(0,0,A)	A
13	(6,1,R)	RR
14	(0,0,O)	O
15	(0,0,E)	E
16	(4,2,E)	RRE
17	(0,0,C)	C
18	(6,1,N)	ON
19	(4,1,R)	ER
20	(1,1,E)	RE
21	(0,0,B)	B

22	(0,0,A)	A
23	(5,2,I)	RRI
24	(0,0,L)	L

Las tuplas LZ son:

(0, 0, <i>E</i>)	(0, 0, <i>R</i>)	(1, 1, <i>E</i>)	(0, 0, <i>C</i>)
(0, 0, <i>O</i>)	(0, 0, <i>N</i>)	(4, 1, <i>R</i>)	(1, 1, <i>E</i>)
(0, 0, <i>C</i>)	(0, 0, <i>I</i>)	(0, 0, <i>G</i>)	(0, 0, <i>A</i>)
(6, 1, <i>R</i>)	(0, 0, <i>O</i>)	(0, 0, <i>E</i>)	(4, 2, <i>E</i>)
(0, 0, <i>C</i>)	(6, 1, <i>N</i>)	(4, 1, <i>R</i>)	(1, 1, <i>E</i>)
(0, 0, <i>B</i>)	(0, 0, <i>A</i>)	(5, 2, <i>I</i>)	(0, 0, <i>L</i>)

Podemos agrupar toda la reconstrucción:

E+R+RE+C+O+N+ER+RE+C+I+G+A+RR+O+E+RRE+C+ON+ER+RE+B+A+RRI+L

Resultado que coincide con la cadena original:
ERRECONERRECIGARROERRECONERREBARRIL

b) Aplicación de **LZW**

Asignamos códigos comenzando desde 0

Código Símbolo

0	E
1	R
2	C
3	O
4	N
5	I
6	G
7	A
8	B
9	L

Luego se agregan:

Código Nueva entrada

10	ER
11	RR
12	RE
13	EC
14	CO
15	ON
16	NE
17	ERR
18	REC
19	CI
20	IG
21	GA
22	AR
23	RRO
24	OE
25	ERRE
26	ECO
27	ONE
28	ERREB
29	BA
30	ARR
31	RI
32	IL

Con el diccionario obtenemos:

0, 1, 1, 0, 2, 3, 4, 10, 12, 2, 5, 6, 7, 11, 3, 17, 13, 15, 25, 8, 22, 1, 5, 9

#	Código emitido	Cadena representada
1	0	E
2	1	R
3	1	R
4	0	E
5	2	C
6	3	O
7	4	N
8	10	ER
9	12	RE
10	2	C
11	5	I
12	6	G
13	7	A
14	11	RR
15	3	O
16	17	ERR
17	13	EC
18	15	ON
19	25	ERRE
20	8	B
21	22	AR
22	1	R
23	5	I
24	9	L

Descompresión. A partir del diccionario, tenemos que:

$0 \rightarrow E$

$1 \rightarrow R$

$1 \rightarrow R$

$0 \rightarrow E$

$2 \rightarrow C$

$3 \rightarrow O$

$4 \rightarrow N$

$10 \rightarrow ER$

$12 \rightarrow RE$

$2 \rightarrow C$

$5 \rightarrow I$

$6 \rightarrow G$

$7 \rightarrow A$

$11 \rightarrow RR$

$3 \rightarrow O$

$17 \rightarrow ERR$

$13 \rightarrow EC$

$15 \rightarrow ON$

$25 \rightarrow ERRE$

$8 \rightarrow B$

$22 \rightarrow AR$

$1 \rightarrow R$

$5 \rightarrow I$

$9 \rightarrow L$

Concatenando:

E+R+R+E+C+O+N+ER+RE+C+I+G+A+RR+O+ERR+EC+ON+ERRE+B+AR+R+I+L

ERRECONERRECIGARROERRECONERREBARRIL

c) Comparación final:

Característica	LZ77	LZW
Estructura	Ventana de búsqueda + anticipación	Diccionario
En este ejercicio	Ventana = 6	Diccionario creciente
Qué busca	Coincidencias recientes	Cadenas ya aprendidas
Repetición aprovechada	Local	Patrones/secuencias aprendidas
Representación	(<i>distancia, longitud, siguiente</i>)	Código numérico
Diccionario explícito	No	Sí
Puede formar frases largas	Limitado por la ventana	Sí, progresivamente
Ejemplo en esta cadena	RE , RR , RRE	ER , ERR , ERRE

7.

Dividimos según las probabilidades acumuladas:

Símbolo	Probabilidad	Intervalo
A	0,50	[0, 0, 50)
B	0,30	[0, 50, 0, 80)
C	0,20	[0, 80, 1)

Por lo tanto:

$$A = [0, 0, 50), \quad B = [0, 50, 0, 80), \quad C = [0, 80, 1)$$

La regla que utilizamos es:

$$L' = L + (H - L)F_{\text{inferior}}$$

$$H' = L + (H - L)F_{\text{superior}}$$

Primer símbolo: A

Comenzamos con:

$[0, 1)$

Como A ocupa:

$[0, 0,50)$

el nuevo intervalo es:

$[0, 0,50)$

Segundo símbolo: B

Tenemos actualmente:

$[0, 0,50)$

El ancho es:

$$0,50 - 0 = 0,50$$

B ocupa del 50% al 80% del intervalo.

Entonces:

$$L' = 0 + 0,50 \cdot (0,50)$$

$$L' = 0,25$$

y:

$$H' = 0 + 0,50 \cdot (0,80)$$

$$H' = 0,40$$

Por lo tanto:

$[0,25, 0,40)$

Tercer símbolo: A

Tenemos:

$[0,25, 0,40)$

El ancho es:

$$0,40 - 0,25 = 0,15$$

A ocupa el primer 50%:

$$L' = 0,25 + 0,15 \cdot (0)$$

$$L' = 0,25$$

$$H' = 0,25 + 0,15 \cdot (0,50)$$

$$H' = 0,325$$

Entonces:

[0,25, 0,325)

Cuarto símbolo: C

Ahora tenemos:

[0,25, 0,325)

El ancho es:

$$0,325 - 0,25 = 0,075$$

C ocupa desde 0,80 hasta 1.

Entonces:

$$L' = 0,25 + 0,075 \cdot (0,80)$$

$$L' = 0,25 + 0,06$$

$$L' = 0,31$$

y:

$$H' = 0,25 + 0,075 \cdot (1)$$

$$H' = 0,325$$

Por lo tanto:

[0,31, 0,325)

Quinto símbolo: A

Tenemos:

[0,31, 0,325)

El ancho es:

$$0,325 - 0,31 = 0,015$$

A ocupa el primer 50%:

$$L' = 0,31$$

$$H' = 0,31 + 0,015 \cdot (0,50)$$

$$H' = 0,31 + 0,0075$$

$$H' = 0,3175$$

Por lo tanto, el intervalo final es:

[0,31, 0,3175)

Ahora por ejemplo si elegimos: $x=0,3125$

$$0,31 < 0,3125 < 0,3175$$

entonces: $x=0,3125$

Es una representación válida de ABACA

b)

Ahora vamos a demostrar que si recibimos:

$$x = 0,3125$$

podemos recuperar:

ABACA

Comenzamos con:

[0, 1)

Los intervalos son:

$$A = [0, 0,50)$$

$$B = [0,50, 0,80)$$

$$C = [0,80, 1)$$

Como:

$$0,3125 \in [0, 0,50)$$

el primer símbolo es:

A

Nos quedamos con:

$$[0, 0,50)$$

Dividimos $[0, 0,50)$. Los intervalos son:

$$A: [0, 0,25)$$

$$B: [0,25, 0,40)$$

$$C: [0,40, 0,50)$$

Nuestro valor es 0,3125 y:

$$0,3125 \in [0,25, 0,40)$$

Por lo tanto:

B

Tenemos: AB

Ahora trabajamos con $[0,25, 0,40)$. Sus subdivisiones son:

$$A: [0,25, 0,325)$$

$$B: [0,325, 0,37)$$

$$C: [0,37, 0,40)$$

Como:

$$0,3125 \in [0,25, 0,325)$$

obtenemos:

A

Tenemos: ABA

Ahora con $[0,25, 0,325)$. Subdividimos:

- A: $[0,25, 0,2875)$
-
- B: $[0,2875, 0,31)$
-
- C: $[0,31, 0,325)$
-

Nuestro valor 0,3125 pertenece a:

$[0,31, 0,325)$

Por lo tanto:

C

Tenemos: ABAC

Finalmente trabajamos con $[0,31, 0,325)$. Sus subdivisiones son:

- A: $[0,31, 0,3175)$
-
- B: $[0,3175, 0,325)$
-
- C: $[0,325, 0,325)$
-

Nuestro valor 0,3125 está dentro de:

$[0,31, 0,3175)$

Por lo tanto:

A

Y recuperamos:

ABACA

Resumen de la decodificación

Paso	Valor 0,3125 cae en	Símbolo
1	$[0, 0,50)$	A
2	$[0,25, 0,40)$	B
3	$[0,25, 0,325)$	A
4	$[0,31, 0,325)$	C
5	$[0,31, 0,3175)$	A

Por lo tanto:

$0,3125 \rightarrow ABACA$

Se recupera exactamente la secuencia original.

Parte 2, Fuentes de Markov:

Ejercicio 1:

AABABACABABACABBABAACAB|AC

Alfabeto = {A, B, C, |}

Matriz de transición:

Normalización:

Para A:

$$P(A|A) = 2/13$$

$$P(A|B) = 7/13$$

$$P(A|C) = 4/13$$

$$P(A| |) = 0/13 = 0$$

Para B:

$$P(B|A) = 6/8 = 3/4$$

$$P(B|B) = 1/8$$

$$P(B|C) = 0/8 = 0$$

$$P(B| |) = 1/8$$

Para C:

$P(C|A) = 3/3 = 1$; Solo tenemos 3 c's ya que la última c no presenta evidencia observable.

$$P(C|B) = 0/3 = 0$$

$$P(C|C) = 0/3 = 0$$

$$P(C| |) = 0/3 = 0$$

Para |:

$$P(| | A) = 1/1 = 1$$

$$P(| | B) = 0/1 = 0$$


$$P(| | C) = 0/1 = 0$$

$$P(| | |) = 0/1 = 0$$

Así obtenemos:

$$P = \begin{pmatrix} \frac{2}{13} & \frac{7}{13} & \frac{4}{13} & 0 \\ \frac{3}{4} & \frac{1}{8} & 0 & \frac{1}{8} \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \end{pmatrix}$$

Grafo:



Ejercicio 2

a_ Obtener la matriz estacionaria (distribución a la que tiende)

La distribución estacionaria es un vector:

$$\pi = (\pi_A, \pi_B, \pi_C, \pi_I)$$

que cumple: $\pi P = \pi$

y además:

$$\pi_A + \pi_B + \pi_C + \pi_I = 1$$

De $\pi P = \pi$:

$$\pi_A = \frac{2}{13}\pi_A + \frac{3}{4}\pi_B + \pi_C + \pi_{|}$$

$$\pi_B = \frac{7}{13}\pi_A + \frac{1}{8}\pi_B$$

$$\pi_C = \frac{4}{13}\pi_A$$

$$\pi_{|} = \frac{1}{8}\pi_B$$

Luego para despejar π_B

$$\pi_B - \frac{1}{8}\pi_B = \frac{7}{13}\pi_A$$

$$\frac{7}{8}\pi_B = \frac{7}{13}\pi_A$$

$$\pi_B = \frac{8}{13}\pi_A$$

Además para $\pi_{|}$:

$$\pi_{|} = \frac{1}{8} \frac{8}{13}\pi_A = \frac{1}{13}\pi_A$$

Luego usando la condición de normalización de que los valores de $\pi_A + \pi_B + \pi_C + \pi_{|} = 1$

despejamos π_A

$$\pi_A + \frac{8}{13}\pi_A + \frac{4}{13}\pi_A + \frac{1}{13}\pi_A = 1$$

$$\frac{26}{13}\pi_A = 1$$

$$\pi_A = \frac{1}{2}$$

Luego como π_B , π_C , $\pi_{|}$ están expresados con π_A , despejamos

$$\pi_B = \frac{8}{13} \frac{1}{2} = \frac{4}{13}$$

$$\pi_C = \frac{4}{13} \frac{1}{2} = \frac{2}{13}$$

$$\pi_I = \frac{1}{13} \frac{1}{2} = \frac{1}{26}$$

Por tanto:

$$\pi = \left(\frac{1}{2}, \frac{4}{13}, \frac{2}{13}, \frac{1}{26} \right) = \pi = \left(\frac{13}{26}, \frac{8}{26}, \frac{4}{26}, \frac{1}{26} \right) =$$

$$\pi \approx (0.5000, 0.3077, 0.1538, 0.0385)$$

b_ Comprobar que las potencias sucesivas de la matriz de transición tienen menor variabilidad en los valores de sus componentes

La idea es que, al aumentar n, las filas de P^n van aproximándose entre sí y acercándose a la distribución estacionaria:

$$\pi = (0.5, 0.3077, 0.1538, 0.0385)$$

$$P^2 \approx \begin{pmatrix} 0.7352 & 0.1501 & 0.0473 & 0.0673 \\ 0.3341 & 0.4195 & 0.2308 & 0.0156 \\ 0.1538 & 0.5385 & 0.3077 & 0 \\ 0.1538 & 0.5385 & 0.3077 & 0 \end{pmatrix} \quad P^5 \approx \begin{pmatrix} 0.4265 & 0.3570 & 0.1872 & 0.0294 \\ 0.5518 & 0.2730 & 0.1304 & 0.0449 \\ 0.6083 & 0.2351 & 0.1047 & 0.0518 \\ 0.6083 & 0.2351 & 0.1047 & 0.0518 \end{pmatrix}$$

$$P^{10} \approx \begin{pmatrix} 0.5106 & 0.3006 & 0.1490 & 0.0398 \\ 0.4925 & 0.3127 & 0.1572 & 0.0375 \\ 0.4844 & 0.3181 & 0.1609 & 0.0365 \\ 0.4844 & 0.3181 & 0.1609 & 0.0365 \end{pmatrix} \quad P^{20} \approx \begin{pmatrix} 0.5002 & 0.3075 & 0.1537 & 0.0385 \\ 0.4998 & 0.3078 & 0.1539 & 0.0384 \\ 0.4997 & 0.3079 & 0.1540 & 0.0384 \\ 0.4997 & 0.3079 & 0.1540 & 0.0384 \end{pmatrix}$$

Como podemos ver las filas se hacen prácticamente iguales al vector de la distribución estacionaria

Por lo tanto

$$\lim_{n \rightarrow \infty} P^n = \begin{pmatrix} \pi \\ \pi \\ \pi \\ \pi \end{pmatrix}$$

c_ Comprobar que la distribución estacionaria es la misma para el cuadrado de la matriz de transición.

Utilizamos P^2 calculado anteriormente

$$P^2 = \begin{pmatrix} 0.7352 & 0.1501 & 0.0473 & 0.0673 \\ 0.3341 & 0.4195 & 0.2308 & 0.0156 \\ 0.1538 & 0.5385 & 0.3077 & 0 \\ 0.1538 & 0.5385 & 0.3077 & 0 \end{pmatrix}$$

Como sabemos que:

$$\pi P = \pi$$

entonces:

$$\begin{aligned} \pi P^2 &= (\pi P)P \\ &= \pi P \end{aligned}$$

$$\pi P^2 = \pi$$

Por lo tanto: $\pi = (0.5, 0.3077, 0.1538, 0.0385)$

Por lo tanto la distribución estacionaria de P y de P^2 es la misma.

Esto no es una casualidad, si π es estacionaria para P , también lo será para cualquier potencia P .

d_ ¿Es un proceso ergódico?

Para una cadena de Markov finita, una condición suficiente para que sea ergódica es que sea:

1. Irreducible
2. Aperiódica

1. Irreducibilidad

Desde cualquier estado podemos llegar a cualquier otro, por tanto si es irreducible

2. Aperiodicidad

Existe un bucle con probabilidad mayor a 0, existe en A, ya que $A \rightarrow A$

Debido a que se cumplen ambas condiciones el proceso es ergódico.

Ejercicio 3

Demostrar que las filas de la matriz de transición son linealmente dependientes en un proceso de Markov

Si calculamos el determinante $\det(P)$, como las filas 3 y 4 son iguales, necesariamente: $\det(P) = 0$. Una matriz cuadrada con determinante cero tiene filas linealmente dependientes.

Ejercicio 4

Sea $S = (s_1, s_2, s_3, s_4)$ $p(s_i | s_{j1}, s_{j2}, s_{j3})$

a_ ¿De qué orden es el sistema de Markov?.

Por definición, el orden de una fuente de Markov indica cuántos estados anteriores son necesarios para determinar la probabilidad del estado siguiente.

Tenemos:

$p(s_i | s_{j1}, s_{j2}, s_{j3})$ y aparecen 3 estados anteriores:

s_{j1}, s_{j2}, s_{j3}

Por lo tanto es un proceso de Markov de tercer orden.

b_

Esto se obtiene directamente de:

$S = (s_1, s_2, s_3, s_4)$

Hay cuatro posibles estados, por tanto 4 estados.

c_ Supuestas conocidas todas las probabilidades condicionales ¿cuál será la forma del sistema de ecuaciones para encontrar las $p(s_i)$?

Como es un proceso de tercer orden, la probabilidad de un estado depende de los tres estados anteriores.

Para obtener $p(s_i)$, aplicamos la ley de probabilidad total sobre todas las posibles combinaciones de los tres estados anteriores.

Como tenemos 4 estados y necesitamos considerar 3 posiciones anteriores, existen:

$4^3 = 64$ combinaciones posibles.

$$\begin{aligned} p(s_1) = & p(s_1 | s_1, s_1, s_1) p(s_1, s_1, s_1) \\ & + p(s_1 | s_1, s_1, s_2) p(s_1, s_1, s_2) \\ & + \dots \\ & + p(s_1 | s_4, s_4, s_4) p(s_4, s_4, s_4) \end{aligned}$$

Por ejemplo para s_1

Y de la misma forma para otros estados

En forma general:

$$p(s_i) = \sum_{j_1=1}^4 \sum_{j_2=1}^4 \sum_{j_3=1}^4 p(s_i | s_{j_1}, s_{j_2}, s_{j_3}) p(s_{j_1}, s_{j_2}, s_{j_3}) \quad \text{para } i = 1, 2, 3, 4$$

Ejercicio 5

Las condiciones son:

1. Si hoy anda, hay un 75% de probabilidad de que mañana también ande:

$$P(1|1)=0.75$$

2. Si hoy no anda, mañana la arreglan:

$$P(1|2) = 1$$

Como las probabilidades de cada fila deben sumar 1:

$$P(2|1)=1-0.75=0.25$$

$$P(2|2)=1-1=0$$

a_

$$P = \begin{pmatrix} P(1|1) & P(2|1) \\ P(1|2) & P(2|2) \end{pmatrix} = \begin{pmatrix} 0.75 & 0.25 \\ 1 & 0 \end{pmatrix}$$

b_

$$\begin{aligned} P &= \begin{pmatrix} 0.7500 & 0.2500 \\ 1.0000 & 0 \end{pmatrix} \\ P^2 &= \begin{pmatrix} 0.8125 & 0.1875 \\ 0.7500 & 0.2500 \end{pmatrix} \\ P^3 &= \begin{pmatrix} 0.7969 & 0.2031 \\ 0.8125 & 0.1875 \end{pmatrix} \\ P^4 &= \begin{pmatrix} 0.8008 & 0.1992 \\ 0.7969 & 0.2031 \end{pmatrix} \\ P^5 &= \begin{pmatrix} 0.8003 & 0.1997 \\ 0.8008 & 0.1992 \end{pmatrix} \end{aligned}$$

Se observa que las filas de las potencias sucesivas se van acercando entre sí. Además, se aproximan a: (0.8, 0.2). Es decir, a largo plazo la máquina estará aproximadamente 80% del tiempo funcionando y 20% del tiempo sin funcionar. Esto nos anticipa la distribución estacionaria

Buscamos:

$$\pi = (\pi_1, \pi_2)$$

tal que:

$$\boxed{\pi P = \pi}$$

Además:

$$\pi_1 + \pi_2 = 1$$

Tenemos:

$$(\pi_1, \pi_2) \begin{pmatrix} 0.75 & 0.25 \\ 1 & 0 \end{pmatrix} = (\pi_1, \pi_2)$$

De la primera componente:

$$0.75\pi_1 + \pi_2 = \pi_1$$

Pasamos $0.75\pi_1$ al otro lado:

$$\pi_2 = 0.25\pi_1$$

Como:

$$\pi_1 + \pi_2 = 1$$

sustituimos:

$$\pi_1 + 0.25\pi_1 = 1$$

$$1.25\pi_1 = 1$$

$$\boxed{\pi_1 = 0.8}$$

Entonces:

$$\pi_2 = 0.25(0.8) = 0.2$$

Por lo tanto:

$$\boxed{\pi = (0.8, 0.2)}$$

Cuando hablamos de la matriz estacionaria/de equilibrio como el límite de las potencias:

$$\lim_{n \rightarrow \infty} P^n$$

Todas las filas convergen a π

$$P^\infty = \begin{pmatrix} 0.8 & 0.2 \\ 0.8 & 0.2 \end{pmatrix}$$

Tal como adelantamos antes.

Es decir, a largo plazo la máquina estará aproximadamente 80% del tiempo funcionando y 20% del tiempo sin funcionar.

Ejercicio 6

Dado un proceso de Markov con tres estados a,b,c; con las siguientes probabilidades:

$p(a/a)=3/4$; $p(c/c)=p(b/b)=1/2$; $p(b/a)=p(c/a)=1/8$; $p(a/b)=p(c/b)=p(a/c)=p(b/c)=1/4$ comprobar que la longitud de Markov para un código compacto $LM = 11/8 < 12/8 = L$

$$S = \{a, b, c\}$$

$$P = \begin{pmatrix} \frac{3}{4} & \frac{1}{8} & \frac{1}{8} \\ \frac{1}{4} & \frac{1}{2} & \frac{1}{4} \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{2} \end{pmatrix}$$

Primero obtenemos las probabilidades estacionarias

Necesitamos saber con qué frecuencia aparece cada estado.

$$\pi = (\pi_a, \pi_b, \pi_c)$$

$$\text{Con } \pi P = \pi$$

Por simetría entre b y c:

$$\pi_b = \pi_c \text{ Entonces si tomamos: } \pi_b = \pi_c = x$$

Como las probabilidades suman 1:

$$\pi_a + 2x = 1$$

De la ecuación correspondiente a a:

$$\pi_a = \frac{3}{4}\pi_a + \frac{1}{4}\pi_b + \frac{1}{4}\pi_c$$

Luego, como $\pi_b = \pi_c = x$

$$\pi_a = \frac{3}{4}\pi_a + \frac{1}{2}x$$

$$\frac{1}{4}\pi_a = \frac{1}{2}x$$

$$\pi_a = 2x$$

Entonces:

$$2x + x + x = 1$$

$$4x = 1$$

$$x = \frac{1}{4}$$

Por tanto:

$$\pi_a = \frac{1}{2}, \quad \pi_b = \frac{1}{4}, \quad \pi_c = \frac{1}{4}$$

La idea es que el código que utilizamos para el siguiente símbolo depende del estado actual.

Las probabilidades si estamos en a son:

$$P(a|a) = \frac{3}{4}, \quad P(b|a) = \frac{1}{8}, \quad P(c|a) = \frac{1}{8}$$

El código de Huffman compacto puede ser:

Siguiente estado	Probabilidad	Código	Longitud
a	3/4	0	1
b	1/8	10	2
c	1/8	11	2

Por tanto la longitud media cuando estamos en a, es:

$$L_a = \frac{3}{4}(1) + \frac{1}{8}(2) + \frac{1}{8}(2)$$

$$L_a = \frac{3}{4} + \frac{1}{4} + \frac{1}{4}$$

$$L_a = \frac{5}{4}$$

Si estamos en b, las probabilidades son:

$$P(a|b) = \frac{1}{4}, \quad P(b|b) = \frac{1}{2}, \quad P(c|b) = \frac{1}{4}$$

Un código compacto es:

Siguiente estado	Probabilidad	Código	Longitud
b	1/2	0	1
a	1/4	10	2
c	1/4	11	2

Por tanto:

$$L_b = \frac{1}{2}(1) + \frac{1}{4}(2) + \frac{1}{4}(2)$$

$$L_b = \frac{3}{2}$$

Para c ocurre exactamente lo mismo:

$$L_c = \frac{3}{2}$$

Ahora tenemos que ponderar cada longitud según la probabilidad de encontrarnos en cada estado:

$$L_M = \pi_a L_a + \pi_b L_b + \pi_c L_c$$

$$L_M = \frac{1}{2} \frac{5}{4} + \frac{1}{4} \frac{3}{2} + \frac{1}{4} \frac{3}{2}$$

$$L_M = \frac{11}{8} \quad \text{Por lo tanto obtenemos: } L_M = 1.375 \text{ bits/símbolo}$$

Ahora hacemos un código que no utiliza la memoria de Markov.

Las probabilidades marginales de los símbolos son las estacionarias:

$$P(a) = \frac{1}{2}, \quad P(b) = \frac{1}{4}, \quad P(c) = \frac{1}{4}$$

Símbolo	Probabilidad	Código	Longitud
---------	--------------	--------	----------

a	1/2	0	1
---	-----	---	---

b	1/4	10	2
---	-----	----	---

c	1/4	11	2
---	-----	----	---

Su longitud media es:

$$L = \frac{1}{2}(1) + \frac{1}{4}(2) + \frac{1}{4}(2)$$

$$L = \frac{3}{2} \text{ o bien } 1.5 \text{ bits/símbolo.}$$

$$1.375 < 1.5$$

La diferencia es $1.5 - 1.375 = 0.125$ bits/símbolo

El ejercicio demuestra que usar la memoria de la fuente permite comprimir mejor.

Cuando sabemos que el estado actual es a, por ejemplo, sabemos que es mucho más probable que el próximo símbolo también sea a:

Por eso podemos asignarle un código corto.

En cambio, el código sin memoria solamente conoce: $P(a) = \frac{1}{2}$

y no aprovecha que la probabilidad del próximo símbolo depende del símbolo actual.

Y se verifica
$$L_M = \frac{11}{8} < \frac{12}{8} = L$$

Ejercicio 7

Usando el texto ERRECONERRECIGARROERRECONERREBARRIL

- Codificar mediante los métodos: Huffman, Fano y Shannon como fuente de Markov de orden 1.
- Relevar para la fuente la estadística de primer orden y realizar una codificación predictiva.
- Realizar una transformación Burrows-Wheller y codificar mediante cuenta de símbolos iguales (RLE).
- Obtener los porcentajes de compresión y comparar los resultados obtenidos.

a_

En una fuente de Markov de orden 1, la probabilidad del próximo símbolo depende del símbolo actual:

$$P(X_{n+1}|X_n)$$

Estadísticas de primer orden: Contamos los símbolos que aparecen después de cada carácter y en base a eso calculamos las probabilidades del siguiente símbolo

Actual	Próximo	Probabilidad
--------	---------	--------------

A	R	1
---	---	---

B	A	1
---	---	---

C	O	2/3
---	---	-----

C	I	1/3
---	---	-----

E	R	1/2
---	---	-----

E	C	3/8
---	---	-----

E	B	$1/8$
---	---	-------

G	A	1
---	---	---

I	G	$1/2$
---	---	-------

I	L	$1/2$
---	---	-------

N	E	1
---	---	---

O	N	$2/3$
---	---	-------

O	E	$1/3$
---	---	-------

R	R	$1/2$
---	---	-------

R	E	$1/3$
---	---	-------

R	O	$1/12$
---	---	--------

R	I	$1/12$
---	---	--------

Construimos un código Huffman para cada estado anterior.

Desde A

Solo puede aparecer R:

$R \rightarrow 0$

No necesitamos bits para distinguir alternativas porque solamente existe una.

Desde B

$A \rightarrow 0$

Desde C

$O \rightarrow 0, I \rightarrow 1$

Desde E

$R \rightarrow 0, C \rightarrow 10, B \rightarrow 11$

Desde G

$A \rightarrow 0$

Desde I

$G \rightarrow 0, L \rightarrow 1$

Desde N

$E \rightarrow 0$

Desde O

$N \rightarrow 0, E \rightarrow 1$

Desde R

$R \rightarrow 0, E \rightarrow 11, O \rightarrow 100, I \rightarrow 101$

Tabla de bits utilizados:

Contexto	Transiciones	Bits utilizados
A	$A \rightarrow R$	0
B	$B \rightarrow A$	0
C	$C \rightarrow O, C \rightarrow I$	3

E	$E \rightarrow R, C, B$	12
G	$G \rightarrow A$	0
I	$I \rightarrow G, L$	2
N	$N \rightarrow E$	0
O	$O \rightarrow N, E$	3
R	$R \rightarrow R, E, O, I$	20
Total		40 bits

$$L_H = 40 \text{ bits}$$

Aplicando fano la longitud también resulta:

$$L_F = 40 \text{ bits}$$

Con Shannon obtenemos códigos algo menos eficientes.

Por ejemplo para R:

$$P(R|R) = \frac{1}{2} \Rightarrow l_R = 1$$

$$P(E|R) = \frac{1}{3} \Rightarrow l_E = 2$$

$$P(I|R) = \frac{1}{12} \Rightarrow l_I = 4$$

$$P(O|R) = \frac{1}{12} \Rightarrow l_O = 4$$

La longitud total resulta: $L_S = 45 \text{ bits}$

b_

Como tenemos 10 símbolos, podemos usar 4 bits para la representación de los símbolos

Símbolo	Código
---------	--------

A	0000
---	------

B	0001
---	------

C	0010
---	------

E	0011
---	------

G	0100
---	------

I	0101
---	------

L	0110
---	------

N	0111
---	------

O	1000
---	------

R	1001
---	------

La fuente es:

ERRECONERRECIGARROERRECONERREBARRIL

El predictor es de orden 1: $\hat{X}_i = X_{i-1}$

Es decir, predice que el próximo símbolo será igual al anterior. Después hacemos:

$$\text{OREX} = X_i \oplus \hat{X}_i$$

Nota: OREX compara los bits de la fuente con los bits que predijo el predictor. Si son iguales pone 0, y si son diferentes pone 1.

Ejemplo para E y R

			Resultado
0 XOR 1	son diferentes		1
0 XOR 0	son iguales		0
1 XOR 0	son diferentes		1
1 XOR 1	son iguales		0

$$0011 \oplus 1001 = 1010$$

Resultados del predictor + XOR

Pos.	Fuente	Predictor	XOR
1	E	—	0011
2	R	E	1010
3	R	R	0000

4	E	R	1010
5	C	E	0001
6	O	C	1010
7	N	O	1111
8	E	N	0100
9	R	E	1010
10	R	R	0000
11	E	R	1010
12	C	E	0001
13	I	C	0111
14	G	I	0001
15	A	G	0100
16	R	A	1001
17	R	R	0000

18	O	R	0001
19	E	O	1011
20	R	E	1010
21	R	R	0000
22	E	R	1010
23	C	E	0001
24	O	C	1010
25	N	O	1111
26	E	N	0100
27	R	E	1010
28	R	R	0000
29	E	R	1010
30	B	E	0010
31	A	B	0001

32	R	A	1001
----	---	---	-------------

33	R	R	0000
----	---	---	-------------

34	I	R	1100
----	---	---	-------------

35	L	I	0011
----	---	---	-------------

Lo importante es que cuando: $X_i = X_{i-1}$ obtenemos 0000

El primer $E=0011$ se transmite directamente.

Después tenemos los 34 símbolos restantes, que producen:

$34 \times 4 = 136$ bits

El XOR de esos 34 símbolos contiene 52 unos y, por lo tanto: $136 - 52 = 84$ ceros

Los ceros están agrupados en 52 corridas.

Las longitudes de las corridas de ceros son:

2,0,0,1,5,1,4,0,1,1,...2,0,0,1,5,1,4,0,1,1

La corrida más larga es de 7 ceros

Según la diapositiva, un contador de k bits puede representar:

$0, \dots, 2^k - 1$ si tenemos corrida de hasta 7 ceros entonces podemos tomar $k = 3$

Por lo tanto, para este texto, el contador adecuado es de 3 bits

Como tenemos 52 corridas, necesitamos:

$52 \times 3 = 156$ bits, y agregamos los primeros 4 bits del símbolo inicial:

$E=0011$

Entonces $L_{\text{predictivo}} = 156 + 4 = 160$ bits

c_

Ahora hacemos una transformación Burrows-Wheeler (BWT).

Para que la transformación sea invertible agregamos un símbolo centinela que no aparece en el texto:

Tenemos:

ERRECONERRECIGARROERRECONERREBARRIL\$

La BWT produce:

LBGEEEEERRRRNNO\$ICRIOORCCRRRRRREEEEAALa longitud es: 36 porque agregamos \$.

Aplicamos RLE

Ahora buscamos secuencias consecutivas de símbolos iguales:

LBGEEEEERRRRNNO\$ICRIOORCCRRRRRREEEEA

Se descompone como:

L^1B^1G^1E^4R^4N^2O^1\\$^1I^1C^1R^1I^1O^2R^1C^2R^6E^4A^2

Por lo tanto, el RLE queda:

L1 B1 G1 E4 R4 N2 O1 \$1 I1 C1 R1 I1 O2 R1 C2 R6 E4 A2

Tenemos: 18 corridas en lugar de 36 símbolos.

Esto muestra por qué BWT + RLE puede ser efectivo: BWT agrupa símbolos iguales y RLE aprovecha esas repeticiones.

d_

Para los códigos Markov, si tomamos el texto original:

$35 \times 8 = 280$ bits

Huffman

LH=40

Porcentaje de compresión:

$CH = ((280 - 40) / 280) \times 100$

CH=85.71%

Fano

$$LF = 40$$

$$CF = 85.71\%$$

Shannon

$$LS=45$$

$$CS= ((280-45) / 280) \times 100$$

$$CS= 83.93\%$$

Predictiva

$$LP = 160$$

$$CP = ((280-160) / 280) \times 100$$

$$CP = 42.85\%$$

BWT + RLE

No podemos decir simplemente que "18 corridas = 18 símbolos" y calcular un porcentaje, porque cada corrida necesita almacenar (símbolo, cantidad)

Si usamos, por ejemplo, 4 bits para el símbolo y 3 bits para la longitud de corrida (el máximo aquí es 6), cada corrida requiere 7 bits:

$$18 \times 7 = 126 \text{ bits}$$

Además debemos almacenar el centinela y la información necesaria para invertir BWT.

Bajo esa representación concreta, tendríamos aproximadamente: 126 bits

$$CBWT+RLE = ((280-126) / 280) \times 100$$

$$CBWT+RLE \approx 55\%$$

Conclusión

En este ejemplo, Huffman y Fano utilizando el contexto de Markov de orden 1 aprovechan directamente la dependencia entre símbolos, por eso consiguen longitudes muy pequeñas.

Shannon también aprovecha la estadística, pero sus longitudes son algo mayores.